

1 数据集构建


为了在逼真的社交环境中系统评估视听导航方法，我们构建了一个社交驱动的视听导航基准数据集。与现有数据集不同，本数据集摒弃了非关联的环境背景噪声（如雨声、交通声），转而构建了一个完全由人类活动驱动的高密度交互场景，旨在考察机器人在复杂人群中的语义感知与社会合规导航能力。

1.1 视听数据

我们基于 Matterport3D 提供的真实室内 3D 扫描场景构建视觉环境，以确保物理空间的多样性与结构复杂性。

为了构建逼真的室内交互场景，我们将声音环境定义为由任务关键声学事件与人类活动背景噪声共同构成。音频样本来源于 ENMuS、AudioSet 及 Freesound 平台，共计 182 个样本，涵盖 6 个声音事件类别。声音数据严格划分为两类：

- **目标声源：**包含警报声、人类求救声、玻璃破碎声、敲门声。每个 Episode 从中选取 1 类作为导航终点信号。
- **社交干扰声源：**包含人类交谈声（模拟对话语义干扰）与脚步声（模拟移动物理噪声）



1.2 动态社交仿真

数据集的核心在于引入了具有高度随机性与行为多样性的虚拟人类智能体。对于每个导航任务，场景配置遵循以下参数化设置：

- **社交密度：**为了覆盖从空旷到拥挤的多样化场景，每个场景中的人类数量在 $[1, 5]$ 之间均匀随机采样 ($N \sim U(1, 5)$)。
- **行为解耦：**我们将人类的运动状态与发声状态进行正交解耦。人类既可以是静止或

移动的，也可以是沉默或交谈的。

1.3 任务定义

为了精细化评估模型在不同社交维度上的鲁棒性，我们将测试集划分为四个难度层级 (Levels)。所有层级均保持一致的社交密度分布 ($N \in [1, 5]$) 与单目标声源设置 (即每个任务仅包含一类目标声音)，但依据人类智能体的行为模式定义了不同的核心挑战。详细划分如 Table 1 所示。

Table 1: 视听社交导航任务难度分级与干扰设置

难度等级(Level)	人类运动	声学干扰
Level 1	全员静止	无干扰
Level 2	全员静止	仅交谈声
Level 3	混合移动	仅脚步声
Level 4	混合移动	交谈声 + 脚步声

1.4 数据集划分

我们选取 Matterport3D 中的 64 个场景作为训练集，每个场景生成 1000 个 Episode。验证集和测试集各包含 10 个从未在训练中见过的独立场景，每个场景包含 100 个 Episode。

每一个 Episode 由一组参数唯一确定，用于初始化虚拟环境中的导航任务。这些参数被重构为：

- 1. 环境设定：模拟场景 ID 与智能体起始位姿。
- 2. 目标设定：目标声源的类别、位置及对应的音频文件。
- 3. 社交人类智能体设定：
 - 数量 (N)：当前 Episode 中的人数 (1-5 随机)。
 - 行为状态：每个智能体的运动标签与声学标签。
 - 轨迹与音频：对应生成的运动轨迹及绑定的脚步声/交谈声音频文件。

下图展示了本数据集中的一个典型任务场景 (level 4)。智能体的任务是定位并导航至图中黄色声波标记的“呼救声”位置。在场景右侧，存在一组静止的人类智能体正在进

行对话（标记为“交谈声”）。在场景左侧，一名移动的智能体正在穿越走廊。不同于静态障碍物，该智能体的移动伴随着“脚步声”（图中脚印图标所示）。这为智能体提供了关键的听觉线索，使其能在视线受阻的情况下感知到动态障碍物的逼近，从而提前规划避让路径。红色箭头展示了智能体在综合处理上述视听信息后，成功绕过移动行人和静止人群，最终到达目标位置的规划轨迹。

