

# SAVNav: Socially-Aware Audio-Visual Navigation 系统方法概述

## 0. Contributions

系统 + 算法 + 验证。

- 1. Infrastructure & Task:** 建立了首个支持高保真声学模拟与动态人类共存的仿真环境，并定义了 Socially-Aware Audio-Visual Navigation (SAVNav) 任务与 Benchmark。
- 2. Methodology:** 提出了一种**不确定性感知 (Uncertainty-Aware)** 的导航框架。核心机制包括用于视距外预判的**声学虚拟动量注入 (Acoustic Hallucinated Momentum)**，以及解决感知歧义的**主动视听搜索 (Belief-Driven Active Search)**。
- 3. Validation:** 实现了从仿真到真机 (Sim-to-Real) 的完整部署。在 Stretch 3 机器人的实验中，展示了系统在真实复杂声学环境下的鲁棒性，有效减少了视距外碰撞风险。

## 1. 系统架构概览 (System Architecture)

SAVNav 系统旨在解决室内服务机器人在复杂声音环境下的社交导航问题，特别是针对“只闻其声，不见其人”的非视距 (NLOS) 场景。系统采用分层架构，包含感知层 (Perception)、建图层 (Mapping, SAVMap) 和规划层 (Planning, SAVNav)。系统利用 RGB-D 相机、麦克风阵列和里程计数据，输出符合社交规范的导航动作。

## 2. 感知层：多模态特征与不确定性 (Perception Layer)

该层负责将原始传感器数据转化为带有语义信息和不确定性参数的空间观测。

### 2.1 视觉感知 (Visual Perception)

我们利用 YOLOv11 进行人体检测，结合 ImageBind 提取语义特征。为了准确衡量距离越远误差越大的传感器特性以及遮挡带来的影响，我们显式建模了**位置不确定性 (Position Uncertainty)**  $\sigma_p$ ：

$$\sigma_p = \sigma_{sensor} + \sigma_{occ} = (k_d \cdot z^2) + (k_{occ} \cdot (1 - \frac{N_{mask}}{N_{box}}))$$

其中  $z$  为目标深度， $N_{mask}/N_{box}$  表示分割区域占比（反映遮挡程度）， $k_d, k_{occ}$  为系数。此  $\sigma_p$  将决定后续地图中该实体的“模糊”程度。

### 2.2 听觉感知 (Audio Perception)

利用 SELD (Embed-ACCDOA) 模型处理 4 通道 Ambisonics 音频。

- 语义:** 通过 CLAP Matching 将音频特征映射到文本标签。
- 定位:** 获取声源方向 (DoA)。由于音频定位天生存在波动，我们将 DoA 的置信度映射为**角度不确定性**  $\sigma_{ang}$ ：

$$\sigma_{ang} = \sigma_{base} \cdot (1 + k_{unc} \cdot (1 - \|\text{ACCDOA}\|))$$

其中  $\|\text{ACCDOA}\|$  为检测模长（置信度）。声源距离暂时作为开环参数处理。

## 3. 建图层：社交视听地图 (SAVMap)

SAVMap 是系统的核心时空记忆容器，它维护着环境的栅格化表征，由静态语义、动态视觉、动态听觉及社交代价四个图层组成。

### 3.1 动态追踪与状态维护

为了在时序上保持实体的连续性，SAVMap 分别维护视觉和听觉实体的多目标追踪 (MOT)。

- **视觉层 (Visual)**: 采用**混合关联策略**，综合考虑位置欧氏距离与语义特征 (ImageBind) 的余弦相似度，利用匈牙利算法进行匹配。状态保持方面，采用卡尔曼滤波平滑位置，并使用**置信度加权的指数移动平均 (EMA)** 更新语义特征，公式为  $\mathbf{e}_{new} = \alpha c \cdot \mathbf{e}_{obs} + (1 - \alpha c) \cdot \mathbf{e}_{hist}$ ，确保特征随视角变化平滑演进。
- **听觉层 (Audio)**: 针对听觉信号的瞬态性与高噪声，采用基于 DoA 角度差与语义一致性的关联机制。引入**差异化衰减策略**，未匹配声源的置信度按  $C_t = C_{t-1} \cdot \lambda_{audio}$  快速衰减 ( $\lambda_{audio} \ll \lambda_{vis}$ )，从而快速遗忘失效声源。

### 3.2 视听融合与虚拟建模

系统通过**锚定机制 (Anchoring)** 解决模态统一问题。

- 当听觉 DoA 锥体与视觉实体空间重合且语义一致时，声源属性被“锚定”在视觉实体上。
- **未见声源建模 (Unseen Audio Hallucination)**: 针对声源未被锚定（如还在视线死角）的移动声源（e.g., 脚步声），系统会实例化虚拟实体并赋予其**拓扑感知虚拟动量**，这是实现 "Hearing before Seeing" 的核心创新。
  1. **拓扑吸附 (Topological Adsorption)**: 针对脚步声等移动信号，系统沿 DoA 方向进行射线投射，计算与静态地图障碍物的交点，并搜索附近的**拓扑关键点**（如走廊拐角、门口中心）作为虚拟实体的生成位置  $\mathbf{p}_{virt}$ 。这模拟了人类对于“声音来自墙后拐角”的空间推理。
  2. **对抗性速度注入 (Adversarial Velocity Injection)**: 采用保守安全策略，假设该未见实体正以正常步速（如 1.2m/s）从隐蔽处走出。系统赋予其一个**指向机器人的虚拟速度矢量**  $\mathbf{v}_{virt}$ 。该动量将驱动代价层在视线盲区生成延伸的斥力场，迫使机器人在未看到人之前就提前做出防御性避让。

### 3.3 社交代价场 (Social Cost Layer)

我们根据实体的感知状态（可见/不可见、静止/移动）构建多样化的高斯代价模型  $Cost(\mathbf{x})$ ，以实现精细的避障行为。

#### A. 可见人类 (静止)

对于静止或速度极低的人类，采用标准的**各向同性高斯模型 (Isotropic Gaussian)**，建立均匀的个人空间保护区。

$$Cost_{stat}(\mathbf{x}) = A \cdot \exp\left(-\frac{\|\mathbf{x}-\mathbf{p}\|^2}{2\sigma_{base}^2}\right)$$

其中  $\sigma_{base}$  动态耦合了感知层输出的位置不确定性  $\sigma_p$ 。

#### B. 可见人类 (移动中)

采用**非对称各向异性高斯模型**，在速度方向  $\mathbf{v}$  上进行动态延展：

$$Cost_{vis}(\mathbf{x}) = A \cdot \exp\left(-\left(\frac{d_{long}^2}{2\sigma_{long}^2} + \frac{d_{lat}^2}{2\sigma_{base}^2}\right)\right)$$

其中，若点  $\mathbf{x}$  在人前方 ( $d_{long} > 0$ )，纵向方差  $\sigma_{long}$  随速度  $\|\mathbf{v}\|$  线性增加；否则保持基础值  $\sigma_{base}$ 。

#### C. 未见移动声源 (Hearing before Seeing)

针对仅有脚步声的 NLOS 目标，生成沿虚拟速度  $\mathbf{v}_{virt}$  的**长矛状代价场**，以此预判潜在碰撞：

$$Cost_{step}(\mathbf{x}) = A \cdot \exp\left(-\left(\frac{d_{long}^2}{2\sigma_{front}^2} + \frac{d_{lat}^2}{2\sigma_{lat}^2}\right)\right) \cdot \mathbb{I}(d_{long} > 0)$$

$\sigma_{lat}$  由听觉角度不确定性  $\sigma_{ang}$  决定， $\sigma_{front}$  设较大值以覆盖死角区域。

#### D. 未见静止声源 (Probability Cone)

针对谈话声等无方向性声源，构建随距离衰减的**概率锥体场**：

$$Cost_{speech}(\mathbf{x}) = \mathbb{I}(\mathbf{x} \in \Omega_{cone}) \cdot \frac{A}{1+\gamma \cdot \|\mathbf{x} - \mathbf{p}_{src}\|} \cdot \exp\left(-\frac{\theta_{dev}^2}{2\sigma_{ang}^2}\right)$$

## 4. 规划层：双模式导航策略 (Planning Layer)

系统引入双模式状态机，根据对目标的掌握程度在“精确导航”与“主动搜索”之间动态切换。

### 4.1 状态 A：精确导航 (Precision Navigation)

**条件：**目标已被视觉确认。

**算法：**快速行进法 (FMM)。构建基于社交代价的速度场  $S(\mathbf{x})$ ：

$$S(\mathbf{x}) = S_{max} \cdot (1 - w_{soc} \cdot \text{clip}(C_{social}(\mathbf{x}), 0, 1)) + S_{min}$$

求解程函方程  $\|\nabla T\| \cdot S = 1$  得到到达时间场  $T(\mathbf{x})$ ，通过梯度下降  $\mathbf{x}_{k+1} = \mathbf{x}_k - \delta \nabla T$  生成路径。

### 4.2 状态 B：主动视听搜索 (Active Audio-Visual Search)

**条件：**目标位置未知（未锚定的 Audio Entity）。

**算法：**基于**信念图 (Belief Map)** 的信息论搜索。

#### 1. 动态信念更新

维护目标存在概率图  $\mathcal{M}_{belief}$ ：

- **听觉正向注入 (Positive)：**在声源 DoA 锥体区域  $\Omega_{ROI}$  增加概率。  

$$\mathcal{M}^{(t)}(c) = \text{clip}(\mathcal{M}^{(t-1)}(c) + \alpha_{audio} \cdot G(c | \Omega_{ROI}), 0, 1)$$
- **视觉负向修正 (Negative)：**相机扫过的无目标区域进行概率衰减。  

$$\mathcal{M}^{(t)}(c) = \mathcal{M}^{(t-1)}(c) \cdot \lambda_{neg} \quad \text{if } c \in \text{FOV}_{free}$$

#### 2. 视点效用最大化

在候选视点集  $\mathcal{P}$  中选择最优视点  $p^*$ ，最大化效用函数  $U(p)$ ：

$$U(p) = \mathcal{I}_{gain}(p) - \beta \cdot \mathcal{C}_{cost}(p)$$

期望信息增益  $\mathcal{I}_{gain}$  定义为视场内信念值的加权和，并引入**距离衰减因子**  $\gamma(d)$  以惩罚远距离观测：

$$\mathcal{I}_{gain}(p) = \sum_{c \in \text{FOV}(p)} \left[ \mathcal{M}_{belief}(c) \cdot \text{Vis}(p, c) \cdot \underbrace{\exp\left(-\frac{\|c-p\|^2}{2\sigma_{sensor}^2}\right)}_{\gamma(\|c-p\|)} \right]$$

其中  $\text{Vis}(\cdot)$  为基于 Ray-casting 的可见性检查。此策略引导 Agent 主动前往能最大程度消除目标位置不确定性的区域。